



中国空间科学技术
Chinese Space Science and Technology
ISSN 1000-758X, CN 11-1859/V

《中国空间科学技术》网络首发论文

题目: 基于迁移学习的卷积神经网络 SAR 图像目标识别
作者: 陈立福, 武鸿, 崔先亮, 郭正华, 贾智伟
DOI: 10.16708/j.cnki.1000-758X.2018.0060
网络首发日期: 2018-11-18
引用格式: 陈立福, 武鸿, 崔先亮, 郭正华, 贾智伟. 基于迁移学习的卷积神经网络 SAR 图像目标识别[J/OL]. 中国空间科学技术.
<https://doi.org/10.16708/j.cnki.1000-758X.2018.0060>



网络首发: 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式(包括网络呈现版式)排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

出版确认: 纸质期刊编辑部通过与《中国学术期刊(光盘版)》电子杂志社有限公司签约, 在《中国学术期刊(网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊(网络版)》是国家新闻出版广电总局批准的网络连续型出版物(ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

基于迁移学习的卷积神经网络 SAR 图像目标识别

陈立福, 武鸿*, 崔先亮, 郭正华, 贾智伟

长沙理工大学 电气与信息工程学院, 长沙 410114

摘要: 针对卷积神经网络中网络参数随机初始化和参数过多导致的收敛速度慢及过拟合的问题, 提出了一种基于迁移学习监督式预训练的卷积神经网络。首先, 引入迁移学习的思想, 采用小规模数据集作为源域的训练样本, 针对源域中源任务进行监督式训练得到预训练模型; 然后, 构建一个多层的卷积神经网络作为目标域中目标任务的待训练网络, 将源域中获得的预训练模型作为该网络的初始参数, 大规模数据作为目标域的训练样本进行网络的微调, 通过这种基于特征选择的迁移学习, 实现源域到目标域的特征信息迁移; 针对卷积神经网络中全连接层参数过多的问题, 采用卷积层替代全连接层。试验使用美国国防高等研究计划署的移动与静止目标搜索识别 (Moving and Stationary Target Acquisition and Recognition, MSTAR) 数据集中三类目标数据作为源域样本, 十类目标数据作为目标域样本, 结果表明该算法的十类目标识别精度达到了 99.13%, 且具有更快的误差收敛速度。

关键词: 迁移学习; 卷积神经网络; 深度学习; 合成孔径雷达; 预训练模型

中图分类号: TP183; TP751

文献标识码: A

Convolution neural network SAR image target recognition based on transfer learning

CHEN Lifu, WU Hong*, CUI Xianliang, GUO Zhenghua, JIA Zhiwei

School of Electronic and Information Engineering, Changsha University of Science & Technology, Changsha 410114, China

Abstract: Aiming at the problem of slow convergence and over-fitting in convolutional neural networks due to random initialization and excessive parameters of network parameters, a supervised pre-training convolutional neural network was proposed based on transfer learning. Firstly, the idea of transfer learning was introduced, and a small-scale dataset was used as a training sample of the source domain. The source task was supervised and trained for the source task. Secondly, a multi-layer convolutional neural network was constructed as the target domain, then the pre-training model obtained from the source domain was taken as the initial parameter of the network, large-scale dataset was used as a training sample for the target domain to fine-tune the network. Through this feature-based transfer learning, the feature information was transferred from source domain to target domain; aiming at the over-parameterized problem in full connected layer of the convolutional neural network, the full connected layer was replaced by the convolutional layer. Three types of target data in the MSTAR dataset of the US Defense Advanced Research Projects Agency were used as the source domain samples, ten types of target data were used as the target domain samples, the experimental results show that the precision of the ten types of targets is 99.13%, and it has a faster error convergence rate.

Keywords: transfer learning ;convolutional neural networks ;deep learning ;synthetic aperture radar ;pre-training model

基金项目: 国家自然科学基金 (41201468, 81401490); 湖南省教育厅项目 (16B004)

作者简介: 陈立福 (1979-), 男, 讲师, 硕士生导师, lifu_chen@139.com, 研究方向为遥感图像解译, 深度学习

*通讯作者: 武鸿 (1993-), 男, 硕士研究生, 324683763@qq.com, 研究方向为深度学习, 图像处理

合成孔径雷达 (Synthetic Aperture Radar, SAR) 系统具有全天时、全天候的特点, 能够在任何天气状况下, 全天时不间断的有效获取地面信息。星载 SAR 作为对地观测的重要手段, 已广泛应用于农业、工业等领域。随着星载 SAR 成像技术的不断完善, 海量的 SAR 数据需要处理, 因此从大量基于复杂场景的数据集中获取信息并完成识别、分割等任务成为了当前的研究热点^[1-3]。图像目标识别的研究主要包含图像预处理、特征提取、识别与分类三个方面。传统的图像目标识别研究主要基于特征提取方面, 如文献[4]将应用于人脸识别的非负矩阵分解 (Non-negative Matrix Factorization, NMF) 特征应用于 SAR 目标识别; 文献[5]将 SAR 图像映射到流形空间, 提取局部判别嵌入 (Local Discriminant Embedding, LDE) 特征, 然后用于图像目标识别; 基于特征提取的方法有主成份分析 (Principal Component Analysis, PCA)^[6]、单演信号描述^[7]、支持向量机 (Support Vector Machine, SVM)^[8]等。以上方法提取的特征均基于人工设计, 需要大量的试验基础和专业领域知识, 并且由于这些特征都是基于目标的底层视觉特征, 无法充分表征目标的本质属性, 因此在很多情况下无法获得有用的特征, 导致目标识别效果不佳。2006 年, 文献[9]揭开了深度学习 (Deep Learning) 发展的序幕。近年来, 深度学习的模型在图像识别领域展现出了强大的学习能力, 文献[10]提出一种深度卷积神经网络将 ImageNet 数据的分类正确率提升了 9%。随后许多学者在不同的应用背景下提出了多种深度学习模型如栈式消噪自动编码器^[11]、深度置信网络和卷积神经网络 (Convolutional Neural Network, CNN) 等。卷积神经网络作为一种深度学习模型, 由于其权值共享网络结构使得图像可直接作为网络的输入, 卷积神经网络在图像识别领域取得了广泛的应用, 如人脸识别^[12]、行为识别^[13]、医学图像识别^[14]等。

卷积神经网络源于人工神经网络的研究, 是一种包含多隐层的多层感知器深度学习结构, 这种多层的结构通过组合低层特征形成更加抽象的高层表示属性类别或特征, 以发现数据的分布式特征表示。本文针对 SAR 图像数据的目标识别问题, 提出一种基于迁移学习监督式预训练的卷积神经网络, 试验结果表明该算法有效地改善和提升了网络误差收敛和识别精度。

1 基于迁移学习监督式预训练的卷积

神经网络

1.1 卷积神经网络

卷积神经网络是一种多层的监督学习神经网络, 每层由多个二维平面组成, 每个平面又包含多个独立的神经元。典型的卷积神经网络由卷积层、池化层和全连接层3种类型的二维平面层构成。卷积层通过卷积运算, 增强了原信号的特征; 池化层也叫下采样层, 利用图像局部相关性的原理, 对输入图像进行下采样, 在减少数据处理量的同时保留了特征信息; 输出层通过整合具有类别区分性的特征信息, 实现分类器的效果。

(1) 卷积层

在卷积层, 将输入图像或上一层的特征图与该层的卷积滤波器进行卷积加偏置, 通过一个非线性激活函数输出卷积层的特征图 (feature map)。具体计算如下:

$$z = \sum_{i \in I} k_i * x_{i-1} + b_i \quad (1)$$

$$x_i = f(z) \quad (2)$$

式中: x_{i-1} 为上一层输出的特征图; z 为经卷积操作后的特征图输出; x_i 为通过非线性激活函数得到的卷积层最终特征图输出; k 为卷积核; b 为偏置; “*” 为卷积计算 (步长为 1), $f(\cdot)$ 为非线性激活函数。在该算法中选择 ReLU 函数作为非线性激活函数。常用的非线性激活函数如 sigmoid 和 tanh 由于其正负饱和区的梯度都接近于 0, 会出现梯度弥散, 而 ReLU 函数在大于 0 的部分梯度为常数, 因此避免了梯度弥散的问题。同时, 采用 ReLU 函数作为非线性激活函数, 由于只有在输入值为正时有输出, 其余均为零, 使得网络具有了适度的稀疏性, 对于卷积层而言, 提高了网络对数据的表征能力, 加快了网络训练过程的收敛。

(2) 池化层

在池化层, 对卷积层的输出特征图进行下采样, 实现数据的降维。最大值池化采用池化区域中的最大值作为下采样输出, 避免了零元素对区域中数值较大元素的削弱。

$$x_i = \max(x_{i-1}) \quad (3)$$

式中: x_{i-1} 为上一层的输出特征图中对应的一个池化窗口; x_i 表为对应池化窗口的最大值池化输出。

(3) 输出层

传统的 CNN 采用全连接层作为网络输出层输出分类结果, 而 CNN 中大部分训练参数集中于全连接层, 过多的网络参数往往带来过拟合的问题。在本算法中, 采用卷积层替代全连接层作为 CNN 的输出层, 卷积层输出为个数为 N 的特征图 (分别对应样本的 N 个类别), 然后采用 Softmax 进行归一化。Softmax 回归模型是 logistic 回归模型在多元分类问题上的推广, 对于给定的输入 x , Softmax 的假设函数定义如下:

$$\begin{bmatrix} z_1 \\ z_2 \\ \vdots \\ z_k \end{bmatrix} = \frac{1}{\sum_{j=1}^k e^{w_j^T x}} \begin{bmatrix} e^{w_1^T x + b_1} \\ e^{w_2^T x + b_2} \\ \vdots \\ e^{w_k^T x + b_k} \end{bmatrix} \quad (4)$$

式中: z_k 为第 k 个神经元的输出; w^T 和 b 分别为权重和偏置。由式 (4) 可以看出, Softmax 回归模型把神经元的输出构造概率分布, 同时起到了归一化的作用。该算法中损失函数定义为交叉熵损失函数:

$$C = -\sum_k y_k \log z_k \quad (5)$$

式中: y_k 为对应于第 k 类的真实值, 取值为 0 或 1。

1.2 基于迁移学习的监督式预训练

卷积神经网络中包含大量的待训练参数, 在训练开始阶段这些参数通常采用随机初始化的方式, 这使得网络的初始误差会处于一个数值相对较大的位置, 容易导致网络收敛效果差和过拟合的问题。针对这一问题, 提出一种基于特征选择的迁移学习监督式预训练方式, 目的是为了获得源域和目标域中共有的特征表示, 然后基于这些特征表示来实现知识迁移。

迁移学习是一种运用已有的知识对不同但相关的领域进行求解的机器学习方法, 它放宽了传统机器学习中的两个基本假设: 1) 用于学习的训练样本和新的测试样本应满足独立且同分布的条件; 2) 必须有足够多的训练样本才能得到一个好的模型。迁移学习中包含源域 (Source Domain) 和目标域 (Target Domain), 定义^[15]如下:

$$D(s) = \{x, P(x)\} \quad (6)$$

$$D(t) = \{x, P(x)\} \quad (7)$$

式中: $D(s)$ 和 $D(t)$ 分别为源域和目标域; x 和 $P(x)$ 分别为 1 个域中的特征空间和特征空间对应

的边缘概率分布。针对 MSTAR 数据集目标识别任务, 为了建立一种小规模数据到大规模数据的特征迁移学习, 源域的源任务 $T(s)$ 定义为三类目标识别, 目标域的目标任务 $T(t)$ 定义为十类目标识别。由于源域与目标域的数据具有同分布特性, 通过源任务获得的预训练模型来初始化目标任务中的网络参数, 从而实现了源域到目标域的特征信息迁移。

1.3 算法流程

图 1 为基于迁移学习监督式预训练的卷积神经网络目标识别算法流程。算法具体步骤如下:

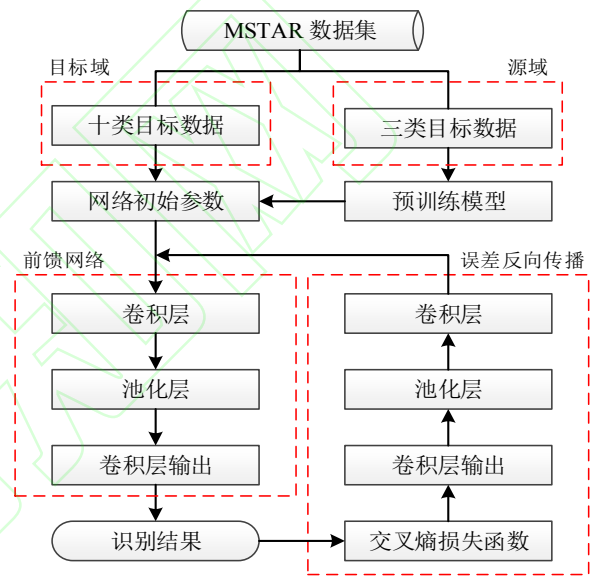


图 1 算法流程

Fig. 1 Algorithm flow chart

(1) 源域预训练

将 MSTAR 中三类目标数据集作为源域训练样本, 针对三类目标识别任务进行有监督地训练卷积神经网络, 得到预训练模型;

(2) 特征信息迁移

构建与预训练模型具有相同结构的卷积神经网络, 将十类目标识别作为目标域的目标任务, 将上一步获得的预训练模型作为该网络的初始参数, 采用十类目标数据作为训练样本对网络进行微调:

1) 前馈网络:

①根据式 (1) 计算卷积, 卷积结果通过式 (2) 的非线性激活函数得到卷积层的输出特征图 x_c ;

②根据式 (3) 对特征图 x_c 进行最大值池化, 输出特征图 x_p ;

③将先前层提取到的特征图通过卷积层输出对应各类的特征图, 最后利用 Softmax 回归模型, 根

据式（4）得到识别结果。

2) 误差反向传播:

根据式（5）交叉熵损失函数计算梯度，采用误差反向传播的方法调整网络的权值和偏置参数，直到误差收敛。

2 试验结果与分析

为了验证算法的有效性，采用美国国防高等研究计划署支持的 MSTAR 公开数据集进行实验，MSTAR 数据集是通过高分辨率的聚束式合成孔径雷达采集到的静止车辆的 SAR 切片图像，包括多类目标的 SAR 图像数据。算法基于 caffe 平台构建卷积神经网络实现，试验环境为：i7-6700（主频 3.4GHz，四核），16GB 内存，训练过程采用 GPU 加速。

2.1 卷积神经网络框架配置

本文算法采用一个包含 5 个卷积层和 4 个池化层的卷积神经网络。MSTAR 数据集训练样本可直接作为网络的输入，图像尺寸缩放为 88×88，最终输出层输出一个 N 维的向量，对应于 N 个类别的概率分布。CNN 网络参数配置如表 1 所示。

表 1 CNN 框架配置

Table 1 CNN frame configuration		
网络层	卷积核/池化	特征图输出
Input	—	88×88×1
Conv-1	5×5×20	84×84×20
Pooling-1	2×2	42×42×20
Conv-2	5×5×40	38×38×40
Pooling-2	2×2	19×19×40
Conv-3	4×4×80	16×16×80
Pooling-3	2×2	8×8×80

表 3 十类目标测试与训练数据分布

Table 3 Ten types of target test and train data distribution										
类别	2S1	BMP2	BRDM	BTR60	BTR70	D7	T62	T72	ZIL	ZSU
测试样本	274	195	274	195	196	274	273	196	274	274
训练样本	299	233	298	256	233	299	299	232	299	299

针对目标域的十类目标识别任务，采用小批量随机梯度下降法训练网络，batchsize 设置为 25；由于采用预训练模型初始化网络参数，学习率设置为

Conv-4	3×3×160	6×6×160
Pooling-4	2×2	3×3×160
Conv-5	3×3×N	1×1×N
Softmax	—	N

2.2 三类目标监督式预训练

算法基于迁移学习的监督式预训练获得预训练模型，采用 MSTAR 中数据规模较小的三类目标数据作为源域训练样本。三类目标数据如表 2 所示，训练样本为方位角 17° 下 BMP2_SN9563、BTR70_C71、T72_SN132 的 SAR 图像数据。三类目标识别框架如表 1 所示，其中 N 设置为 3。

表 2 三类目标训练数据分布

Table 2 Three types of target train data distribution			
类别	BMP2	BTR70	T72
训练样本	233 (SN9563)	233 (C71)	232 (SN132)

针对源域三类目标识别任务，采用小批量随机梯度下降法（Mini-batch Stochastic Gradient Descent, MSGD）训练源域目标网络，批处理数量（batchsize）设置为 25，学习率设置为 0.01。保存训练迭代 60000 次时的网络参数作为预训练模型。

2.3 十类目标训练与测试

为了实现源域到目标域的特征信息迁移，在目标域中构建与源域相同的卷积神经网络框架，如表 1（其中 $N=10$ ）所示，网络初始参数由源域获得的预训练模型得到。目标域中采用十类目标识别样本对网络进行微调。在十类目标数据包括 BMP2、BTR70、T72、2S1、BRDM2、ZSU234、BTR60、D7、T62、ZIL131 十类目标数据，训练样本为方位角 17° 下的十类目标 SAR 图像数据，测试样本为方位角 15° 的十类目标 SAR 图像数据。十类目标测试与训练数据分布如表 3 所示。

源任务的 1/10，即 0.001，最大迭代次数为 60000 次，每迭代 200 次进行一次测试。训练过程在迭代 34200 次时测试正确率达到了 99.13%，十类目标的

识别结果如图 2 所示, 其中对角线上以黑灰色框出的数字表示目标识别正确的数目, 其余表示识别错误的数目及对应错分类别。

2S1	272	0	0	0	1	0	0	0	1	0
BMP2	0	194	0	0	0	1	0	0	0	0
BRDM2	0	0	271	1	0	0	0	2	0	0
BTR60	0	1	0	192	0	0	0	1	1	0
BTR70	0	0	0	0	196	0	0	0	0	0
D7	0	0	0	0	0	274	0	0	0	0
T62	1	0	0	1	0	0	271	0	0	0
T72	0	0	1	1	0	0	0	193	0	1
ZIL131	0	0	1	0	0	0	0	0	273	0
ZSU234	0	0	2	0	0	1	0	0	0	271
	2S1	BMP2	BRDM2	BTR60	BTR70	D7	T62	T72	ZIL131	ZSU234

图 2 十类目标识别结果

Fig. 2 Ten types of target recognition results

2.4 不同算法对比

为了更好地评测本文算法针对目标域十类目标识别的性能, 构建一个采用参数随机初始化的卷积神经网络进行对比。两个网络具有相同的卷积层和池化层, 同样采用卷积层作为网络输出层, 训练过程采用相同的学习率和 batchsize。两个算法的十类目标识别测试正确率对比如表 4 所示, 由正确率对比可以看出本文算法的基于三类目标监督式预训练 CNN 较比网络参数随机初始化的 CNN 识别精度提升了 0.88%。

由于两个卷积神经网络在训练迭代 10000 次以后已基本达到收敛, 所以截取了训练迭代前 10000 次两个算法误差收敛情况如图 3 所示, 由对比曲线可以看出基于监督式预训练的 CNN 由于初始误差较小, 误差的收敛速度和整体收敛情况均优于参数随机初始化的 CNN。测试正确率截取了训练迭代前 15000 次得到对比曲线如图 4 所示, 由对比曲线可以看出基于监督式预训练的 CNN 在整个训练阶段的测试正确率均高于参数随机初始化的 CNN, 具有更高的识别精度。




图 3 训练误差对比

Fig. 3 Train error comparison




图 4 测试正确率对比

Fig. 4 Test accuracy comparison

本文算法是基于小规模数据到大规模数据特征信息迁移的思想, 为了评测源任务中数据规模大小对目标任务的影响, 构建了一个六类目标识别作为源任务实现监督式预训练的 CNN, 最终十类目标识别的正确率如表 4。由表 4 可得六类目标预训练的最终识别精度高于网络参数随机初始化的 CNN, 但略低于三类目标预训练的 CNN, 可能的原因是与三类目标预训练相比, 六类目标预训练的训练样本数据分布以及 CNN 输出层结构与十类目标识别目标任务的相似程度较高, 使得这种特征信息迁移对目标任务的影响较小。考虑一种极端情况, 若采用十类目标做预训练, 而目标任务也为十类目标识别, 这种预训练实际上起到的效果只是训练迭代次数的增加而已。由以上分析可得, 基于小规模数据到大规模数据特征信息迁移的预训练方法, 在确定预训练数据的分布与规模大小时, 不宜与目标任务的训练数据具有过高的相似程度。

表 4 测试正确率对比

Table 4 Test correct rate contrast

CNN	正确率/%
网络参数随机初始化	98.25
六类目标监督式预训练	98.92
三类目标监督式预训练	99.13

3 结束语

本文针对MSTAR数据集中的SAR图像多类目标识别问题,提出了一种基于迁移学习监督式预训练的卷积神经网络。首先,建立一种以三类目标识别作为源域、十类目标识别作为目标域的迁移学习模型;然后基于源域预训练模型进行目标域卷积神经网络的微调,最终实现了源域到目标域的特征信息迁移。通过这种迁移学习的方式,使得目标域充分利用了源域预训练模型的特征信息,加快了卷积神经网络在训练过程的误差收敛速度,在目标域的十类目标识别精度达到了99.13%,相比于参数随机初始化的卷积神经网络,识别精度提升了0.88%。由于本文算法是从大规模数据中抽取部分数据构建源域样本,从而实现特征迁移,故该方法不适用于小规模数据的卷积神经网络训练。今后的研究方向可在源域数据样本分布与规模大小的标准定义上展开。

参考文献 (References)

- [1] 陈立福,文俊,肖红光,等.一种融合MRF分割与数学形态学的道路提取算法[J].中国空间科学技术,2015,35(2):17-24.
CHEN L F, WEN J, XIAO H G, et al. Road extraction algorithm for high resolution SAR image by fusion of MRF segmentation and mathematical morphology[J]. Chinese Space Science and Technology, 2015, 35 (2): 17-24 (in Chinese).
- [2] 王冠勇,张磊,万欣,等.月地双基SAR成像的快速后向投影算法研究[J].中国空间科学技术,2017,37(6):32-39.
WANG G Y, ZHANG L, WAN X, et al. Study on fast back projection algorithm for lunar-earth bistatic SAR imaging[J]. Chinese Space Science and Technology, 2017, 37 (6): 32-39 (in Chinese).
- [3] 梁健,张润宁,包敏凤.天基视频SAR系统设计与成像算法研究[J].中国空间科学技术,2016,36(6):22-28.
LIANG J, ZHANG R L, BAO M F. Research on spaceborne video SAR system design and image formation algorithm[J]. Chinese Space Science and Technology, 2016, 36 (6): 22-28 (in Chinese).
- [4] HUAN R H, PAN Y, MAO K J. SAR image target recognition based on NMF feature extraction and Bayesian decision fusion[C]//2010 Second IITA International Conference on Geoscience and Remote Sensing (IITA-GRS). IEEE, 2010: 496-499.
- [5] PEI J F, HUANG Y L, LIU X, et al. Neighborhood virtual points discriminant embedding for synthetic aperture radar automatic target recognition[J]. Optical Engineering, 2013, 52 (3): 6201.
- [6] LIN C, WANG B, ZHAO X, et al. Optimizing kernel PCA using sparse presentation-based classifier for MSTAR SAR image target recognition[J]. Mathematical Problems in Engineering, 2013 (6): 707-724.
- [7] DONG G, WANG N, KUANG G. Sparse representation of monogenic signal: with application to target recognition in SAR images[J]. IEEE Signal Processing Letters, 2014, 21 (8): 952-956.
- [8] ZHAO Q, PRINCIPE J C. Support vector machines for SAR automatic target recognition[J]. IEEE Transactions on Aerospace and Electronic Systems, 2001, 37 (2): 643-654.
- [9] HINTON G E, OSINDERO S, TEH Y W. A fast learning algorithm for deep belief nets[J]. Neural Computation, 2006, 18(7): 1527-1554.
- [10] KRIZHEVSKY A, SUTSKEVER I, HINTON G E. Image Net Classification with Deep Convolutional Neural Networks[J]. Advances in Neural Information Processing Systems, 2012, 25 (2): 1097-1105.
- [11] VINCENT P, LAROCHELLE H, LAJOIE I, et al. Stacked denoising autoencoders: learning useful representations in a deep network with a local denoising criterion[J]. The Journal of Machine Learning Research, 2010, 11 (12): 3371-3408.
- [12] MA Y, HE J, WU L, et al. An effective face verification algorithm to fuse complete features in convolutional neural network[J]. Springer International Publishing, 2016: 39-46.
- [13] IJJINA E P, MOHAN C K. Human action recognition based on motion capture information using fuzzy convolution neural networks [C]//International Conference on Machine Learning and Applications: IEEE, 2015: 159-164.
- [14] CIOMPI F, DE H B, VAN RIEL S J, et al. Automatic classification of pulmonary peri-fissural nodules in computed tomography using an ensemble of 2D views and a convolutional neural network out-of-the-box[J]. Medical Image Analysis, 2015, 26 (1): 195-202.
- [15] PAN S J, YANG Q. A survey on Transfer Learning[J]. IEEE Transactions on Knowledge & Data Engineering, 2010, 22 (10): 1345-1359.